

SPARK 实践

1、实验目标

本实验旨在介绍学习者如何配置和运行 Apache Spark，以及如何使用 Spark 进行简单的数据处理和分析。实验将涵盖以下内容：

- 1) 安装和配置 Apache Spark。
- 2) 运行一个简单的 Spark 应用程序，以理解 Spark 的基本概念。
- 3) 使用 Spark 进行数据处理和分析。

2、实验环境

虚拟机，在 VMware 上运行 Ubuntu 22.04

因为在大二下彭老师的大数据管理与分析上使用过 Hadoop 和 Spark，且配置了相关环境（幸好还没有删），环境有一定帮助。

以下是虚拟机配置，开了 4g 内存。



3、数据集

老师提供的数据集

sales.csv

<https://pan.baidu.com/s/18eqffdkDTP8cIbZpE8G10w?pwd=xg2p>

4、实验步骤

- 1) 安装和配置 Apache Spark 因为下载过此步跳过
- 2) 运行一个简单的 Spark 应用程序
 - a. 创建一个新的 Spark 应用程序，使用 Python 编写。
 - b. 在应用程序中初始化 SparkSession 对象，它是 Spark 应用程序的入口点。
 - c. 加载示例数据集到 Spark 中。
 - d. 对数据进行一些简单的转换操作，如筛选、映射或聚合。
 - e. 运行 Spark 应用程序并查看结果。

```

from pyspark.sql import SparkSession

# 初始化 SparkSession
spark = SparkSession.builder.appName("SimpleSparkApp").getOrCreate()

# 加载数据
data = spark.read.csv("sales_data.csv", header=True, inferSchema=True)

# 执行一些数据处理操作
result = data.filter(data["product_category"] == "Electronics").groupBy("date").sum("revenue")

# 显示结果
result.show()

```

5、相关 Spark 程序

1) 根据文档运行 word count:

```

your: 1
you: 6
yes: 1
years: 5
writer: 1
wrongful: 1
would: 2
work: 2
words: 3
withering: 1
with: 1
with: 11
winds: 1
will: 20
whose: 1
who: 4
whites: 1
white: 6
whitebends: 1
which: 5
where: 3
when: 5
were: 1
well: 1
we've: 3
we: 18
waters: 1
was: 2
warm: 1
wallow: 1
walk: 1
walk: 1
vote: 1
vote: 1
violence: 1
villages: 1
victims: 1
vicious: 1
veterans: 1

```

2) 使用 Spark 求工作日销量最大的门店 ID :

```
sparksal('selectstore,customer,vgasNfrowglobaltepppeoplexhereDayofNeek>landDayofkeek<-5orderbyNdesc')show()
```

```

+-----+-----+
|Store|Max.C|
+-----+-----+
| 817|7388.0|
| 262|5494.0|
| 262|5458.0|
| 262|5387.0|
| 262|5297.0|
| 262|5192.0|
| 262|5152.0|
| 262|5145.0|
| 262|5132.0|
| 262|5112.0|
| 262|5106.0|
| 262|5090.0|
| 262|5069.0|
| 262|5063.0|
| 262|5034.0|
| 262|5028.0|
| 262|5024.0|
| 262|5014.0|
| 262|5013.0|
| 262|4989.0|

```

3) 使用 Spark 求工作日销量最大的门店 ID, 每个门店出现一次 :

```
spark.sql('select Store, max(Customers+0) as M from global_temp.people where DayofWeek >=1 \
and DayofWeek <=5 group by Store orderby M desc').show()
```

Store	Max.C
817	7388.0
262	5494.0
1114	4911.0
586	4762.0
733	4645.0
251	4635.0
769	4582.0
756	4180.0
562	4099.0
336	3961.0
335	3929.0
1097	3804.0
259	3648.0
320	3507.0
580	3360.0
467	3351.0
513	3302.0
827	3241.0
983	3200.0
470	3178.0

3) 使用 Spark 求平均销量最大的门店 ID, 每个门店出现一次 :

```
datasets<Row> = spark.sql('select Store, avg(Customers+0) as A from \
global_temp.people where DayofWeek >=1 and DayofWeek <=5 group by Store orderby A desc')
```

Store	Avg.C
733	3403.5
262	3402.0
562	3105.1
769	3081.1
1114	2664.1
817	2605.5
1097	2420.9
335	2385.3
259	2347.1
251	2026.5
586	1945.3
756	1940.5
423	1886.1
383	1826.2
682	1758.8
513	1744.7
320	1717.1
948	1687.0
676	1644.6
336	1623.2

6、实验体会

有种回到了大二下被 hadoop 和 spark 支配的感觉。

当然这次没有当初配置 Hadoop 时的呕心沥血，总体来说比较顺利。

可能对于程序员来说，易用方便的环境也是不可缺少的，很难想象早期程序员面对的是什么样的局面。

现在还记得大二下 spark 的特点，基于 RDD 内存计算单元的弹性分布式存储，运算的中间结果可以存在内存里，大大节省了速度。